

EP 2– Tradução Automática de Baixo Recurso

Nome: Gustavo Honda; nUSP: 12543395

Introdução

Este exercício de programação (EP) tem como objetivo explorar a tradução automática em cenários de baixo recurso, utilizando um corpus paralelo Português–Tupi Antigo e modelos de linguagem de grande porte (LLMs). O foco do trabalho é investigar como diferentes abordagens, como zero-shot e few-shot learning, se comportam na tarefa de tradução em ambas as direções linguísticas.

No **modo zero-shot**, o modelo realiza a tradução apenas com base em seu conhecimento prévio, sem receber exemplos específicos da tarefa. Já no **modo few-shot**, seleciona-se um pequeno conjunto de exemplos para refinar o modelo (fine-tuning), permitindo que ele se adapte melhor ao corpus específico. Para este EP, realizamos experimentos que contemplam ambos os cenários, utilizando o T5 como modelo base, com ajustes no número de exemplos e no tamanho do batch para otimizar desempenho e uso de recursos computacionais.

Durante o treinamento e avaliação, adotamos estratégias para lidar com limitações de espaço e memória, incluindo:

- armazenamento de modelos e caches em diretórios alternativos para evitar problemas de disco;
- uso de modelos menores (como T5-small) para reduzir o consumo de memória;
- configuração de checkpoints e salvamento de modelos finetuned em intervalos controlados para economia de espaço.

Descrição do Corpus

O corpus utilizado neste trabalho consiste em um conjunto paralelo de textos em Português e Tupi Antigo, estruturado em duas colunas: uma dedicada ao texto em Português e outra à respectiva tradução em Tupi Antigo. Essa organização permite o uso direto em tarefas de tradução automática, garantindo que cada sentença em Português tenha seu correspondente em Tupi Antigo.

Durante a preparação do corpus, foi necessário realizar limpezas específicas nos dados do Tupi Antigo. Foram removidos valores em branco, aspas, caracteres especiais e quaisquer símbolos que não fossem compatíveis com a codificação UTF-8. Essa limpeza é fundamental para evitar que o modelo aprenda padrões inválidos ou gere saídas inconsistentes durante o treinamento. Mantendo apenas os caracteres válidos, garantimos que o modelo pudesse interpretar corretamente o texto de entrada e gerar traduções coerentes.

Inicialmente, os experimentos foram conduzidos em modo zero-shot, onde o modelo recebe apenas a instrução de tradução sem exemplos adicionais. No entanto, nesse cenário, observou-se um problema recorrente: o modelo frequentemente gerava o token especial <extra_id_0> em suas saídas. Esse comportamento indica uma dificuldade na interpretação da instrução e na geração direta do texto em Tupi Antigo sem um refinamento prévio. Esse resultado motivou a adoção do modo few-shot, permitindo fornecer exemplos específicos ao modelo para melhorar a fidelidade das traduções e reduzir a ocorrência de tokens especiais indesejados.

Origem:

https://github.com/CalebeRezende/oldtupi_dataset/blob/main/C%C3%B3pia%20de%20portugues-guarani-tupi%20antigo.xlsx

Metodologia

Neste trabalho, adotaram-se duas abordagens principais para a tradução automática: zero-shot e few-shot.

No modo zero-shot, o modelo é testado diretamente sem qualquer treinamento específico sobre o corpus de Português–Tupi Antigo. Nesse cenário, o modelo realiza a tradução apenas com base em seu conhecimento prévio, adquirido durante o treinamento genérico em grandes corpora de texto. Esse método permite avaliar a capacidade do modelo de generalizar para domínios não vistos anteriormente, embora possa apresentar limitações, como interpretação incorreta das instruções ou geração de tokens especiais indesejados.

No modo few-shot, o modelo passa por um processo de fine-tuning utilizando um pequeno conjunto de exemplos do corpus paralelo. Esse treinamento com poucos exemplos permite

que o modelo aprenda padrões específicos da tarefa e da língua, aumentando a fidelidade das traduções e reduzindo a ocorrência de erros típicos do zero-shot.

Modelo Utilizado

Para os experimentos, foi utilizado o T5-small, da família T5 (Text-to-Text Transfer Transformer). Trata-se de um modelo seq2seq projetado para converter qualquer tarefa de processamento de linguagem natural em um problema de geração de texto. O T5 é amplamente empregado em tarefas como tradução automática, sumarização, question answering e outras aplicações de NLP.

Corpus e Pré-processamento

O corpus utilizado consiste em textos paralelos em Português e Tupi Antigo, organizados em duas colunas (uma para cada idioma). Antes do treinamento, o corpus passou por pré-processamento para remover:

- valores em branco;
- aspas;
- caracteres especiais;
- quaisquer símbolos fora do padrão UTF-8.

Dessa forma, garantiu-se que o modelo trabalhasse apenas com caracteres válidos, essenciais para o treinamento seq2seq.

O corpus foi dividido em três conjuntos:

1. Treinamento: 70% dos dados;
2. Validação: 15% dos dados;
3. Teste: 15% dos dados.

Para treinar o modelo, ajustar hiperparâmetros com validação e avaliar a performance final de forma confiável.

Configurações

Durante o fine-tuning few-shot, foram utilizadas as seguintes configurações:

- "per_device_train_batch_size = 2"
- "per_device_eval_batch_size = 2"
- "num_train_epochs = 3"
- "learning_rate = 1e-5"

- "weight_decay = 0.01"
- "logging_steps = 20"
- "save_steps = 100"
- "save_total_limit = 2"

Para avaliar a qualidade das traduções, foram utilizadas duas métricas automáticas:

- BLEU (Bilingual Evaluation Understudy): mede a qualidade da tradução comparando n-gramas do texto candidato com n-gramas de traduções de referência (padrão ouro). Pontuações variam entre 0 e 1, sendo valores mais próximos de 1 indicativos de maior similaridade.
- chrF (CHaRacter-level F-score): mede a similaridade entre a tradução automática e a referência usando n-gramas de caracteres, sendo especialmente útil para línguas com morfologia complexa, como o Tupi Antigo.

Após a limpeza do corpus paralelo Português-Tupi Antigo, os textos foram preparados para entrada no modelo T5-small utilizando a tokenização adequada para modelos seq2seq. A tokenização é uma etapa essencial para converter sequências de texto em representações numéricas que o modelo consegue processar.

Para isso, foi utilizado o tokenizer associado ao modelo T5, com os seguintes parâmetros:

"padding=True": preenche sequências menores que o tamanho máximo com tokens de padding, garantindo que todas as entradas do batch tenham o mesmo comprimento;
 "truncation=True": corta sequências maiores que o tamanho máximo permitido, evitando estouro de memória e problemas durante o treinamento;
 "max_length=128": define o comprimento máximo das sequências, garantindo uniformidade no processamento e compatibilidade com os limites do modelo.

Hardware

Todos os experimentos de tradução automática foram realizados em uma máquina com recursos limitados, configurada da seguinte forma:

- GPU: NVIDIA RTX 1050 Ti, 8 GB de memória;
- CPU: Intel i5-7400;
- RAM: 16 GB (ou o valor que você estiver usando, se diferente);
-

Frameworks:

- PyTorch "2.9.1"
- Transformers "4.57.3"

Essa configuração determinou algumas escolhas importantes durante o treinamento, como:

- Batch size reduzido ("per_device_train_batch_size = 2"), para evitar estouro de memória da GPU
- Uso de "fp16" quando a GPU está disponível, reduzindo o consumo de memória e acelerando o treinamento
- Limitação no número de epochs e tamanho máximo de sequência ("max_length = 128") para manter o modelo dentro dos limites de hardware

Testes feitos

Foram feitos 4 testes ao todo:

- Português → Tupi Antigo (zeroshot)
- Tupi Antigo → Português (zeroshot)
- Português → Tupi Antigo (fewshot)
- Tupi Antigo → Português (fewshot)

Resultados e Métricas

	BLEU	chrF1	chrF3
Português → Tupi Antigo (zeroshot)	0.008560276218397986	2.8753654862180693	2.2363953781696098
Tupi Antigo → Português (zeroshot)	0.0	3.057380302092936	2.3779624571833957
Português → Tupi Antigo (fewshot)	0.0025392579954069986	4.48119816923698	3.485376353850985
Tupi Antigo → Português (fewshot)	0.002575632266415711	4.439705503468442	3.453104280475455

Análise linguística qualitativa

Português Tupi Antigo (zeroshot)

Alguns dos resultados:

PRED: <extra_id_0>
REF: Aîmorambûerukar ahẽ rekorambûera

PRED: <extra_id_0>.
REF: Xe py-piru'a

PRED: <extra_id_0>
REF: Ixé aé ã a'é umûã nakó peẽme

PRED: <extra_id_0>
REF: Peïori, peîaîubã pitangĩ-moraûsubara

PRED: <extra_id_0>.
REF: koriteĩ-aíb-eté

O que aconteceu nesse caso é um problema típico de zero-shot em modelos seq2seq como o T5 quando o modelo nunca viu exemplos específicos do par de línguas durante o treinamento. Observando os resultados:

Todas as previsões retornam "<extra_id_0>", que é um token especial do T5 usado internamente para marcação de spans ou preenchimento em tarefas de seq2seq. O modelo não gerou tradução real, apenas retornou esse token especial, ignorando o conteúdo da entrada. Isso ocorre porque, no modo zero-shot, o modelo nunca foi exposto ao Tupi Antigo e ao formato do corpus, então ele não sabe como mapear o português para o Tupi Antigo. Ele interpreta a tarefa de forma muito genérica e acaba retornando tokens de preenchimento. A discrepância entre "<extra_id_0>" e o texto de referência mostra que nenhum aprendizado real de tradução aconteceu.

Tupi Antigo Português(zeroshot)

PRED: <extra_id_0>

REF: Fiz frustrar aquilo que fulano faria

PRED: <extra_id_0>

REF: Eu tenho pes calejados

PRED: <extra_id_0>

REF: Eu mesmo como se viu ja vos disse isso

PRED: <extra_id_0>

REF: Vinde abraçai o nenem compadecedor

PRED: <extra_id_0>

REF: o mais cedo possivel em um momento

De forma semelhante ao caso anterior, praticamente todas as saídas geradas pelo modelo foram o token especial <extra_id_0>, que faz parte do mecanismo interno do T5 para marcação e preenchimento de spans. Em vez de produzir sequências correspondentes em Tupi Antigo, o modelo ignorou o conteúdo semântico do texto em português e retornou apenas esse marcador genérico.

Português Tupi Antigo (fewshot)

PRED: <extra_id_0>ичт

REF: Aïmorambûerukar ahẽ rekorambûera

PRED: <extra_id_0>röj- <extra_id_33>

REF: Xe py-piru'a

PRED: <extra_id_0>- Cmeqpfynhalt

REF: Ixé aé ã a'é umûã nakó peẽme

PRED: <extra_id_0> <extra_id_36> aSparetråderen.bem

REF: Peïori, peïaïubã pitangĩ-moraûsubara

PRED: <extra_id_0>INSIázi'ir <extra_id_1>epositphotosKeywordsus <extra_id_9>

<extra_id_11>ဆ <extra_id_7> <extra_id_10> <extra_id_32>pensadoiулан'

REF: korite'ĩ-aíb-eté

No caso do few shots o modelo mostrou algum sinal de tradução para outras linguas mas não tupi antigo. Talvez o treinamento prévio desse modelo esteja enviesando o resultado.

Tupi Antigo Português (fewshot)

PRED: <extra_id_0>? fémvoeg驚

REF: Fiz frustrar aquilo que fulano faria

PRED: <extra_id_0>)ësyIvfovpleeg <extra_id_53> o'elma величенecetellageli

REF: Eu tenho pes calejados

PRED: <extra_id_0> setTimeout <extra_id_38> <extra_id_51> <extra_id_55>

<extra_id_56>-

REF: Eu mesmo como se viu ja vos disse isso

PRED: ckerblicabeoordelingen

REF: Vinde abraçai o nenem compadecedor

PRED: <extra_id_0>,Unico: <extra_id_51>gxje

REF: o mais cedo possivel em um momento

Conclusões e limitações

Few shots apresentou alguma melhora em relação ao zeroshot, mas longe do ideal. Talvez a escolha de um modelo mais potente, aumentar os hyperparametros ou ter uma máquina mais potente para poder mudar essas duas condições de modelos e hyperparametros ajude no treinamento do modelo e melhorar as métricas.

Por não possuir poder computacional tive que usar o modelo mais simples e pegar bem leve nas métricas de treinamento.

Mas o código não precisaria ser alterado caso os recursos computacionais sejam disponibilizados.